

Regresja_ppodsumowanie

Ewa Bojke

17 grudnia 2019

Dane

Zbiór danych w tym zadaniu pochodzi od Służb Leśnych Departamentu Rolnictwa USA w Kalifornii. Są to dane służące do kalibracji czujnika gęstości. Materiały o dziewięciu różnych, znanych, gęstościach zbadano czujnikiem (każdy przypadek został pomierzony 10-krotnie) i zanotowano wartość sygnału wyjściowego.

Zmienne


zmienna	opis
density	gęstość materiału (g/cm^3)
gain	wartość sygnału wyjściowego

```
gauge <- read.csv("C:/Users/Ewci/Desktop/gauge.csv")
```


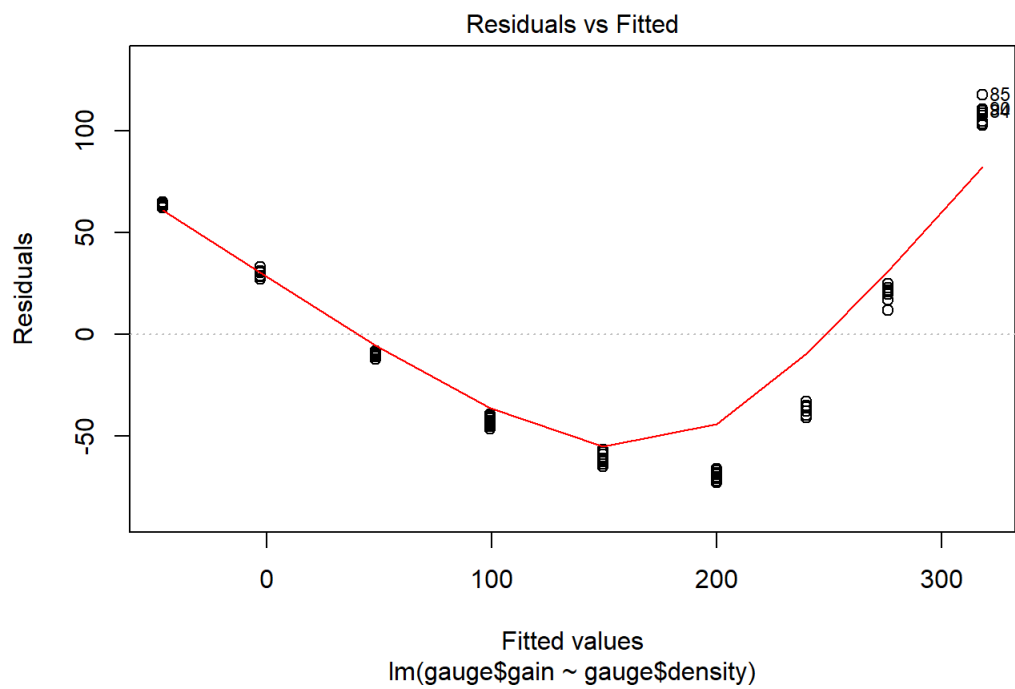
Problemy badawcze

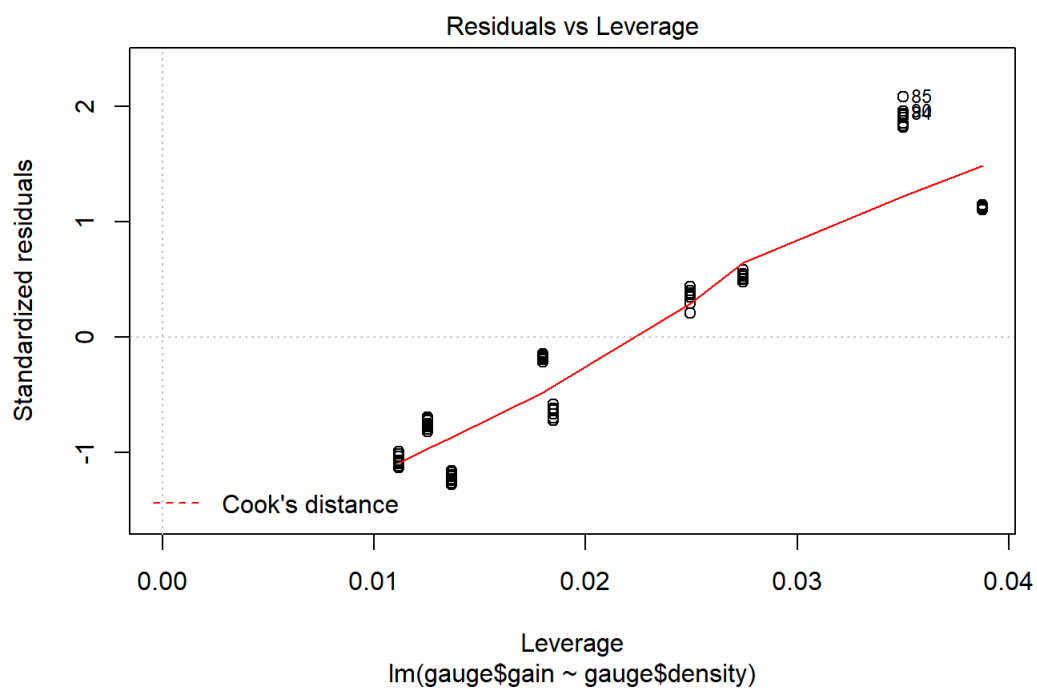

1. Dopasuj model liniowy do naszych danych. Jak wyglądają wykresy diagnostyczne? Odp:

```
model<-lm(gauge$gain~gauge$density)
plot(gauge$density,gauge$gain, xlab="Density", ylab="Gain",xlim=c(-0.2,0.8),ylim=c(-20,600))
abline(model,col="blue")
```



```
plot(model)
```



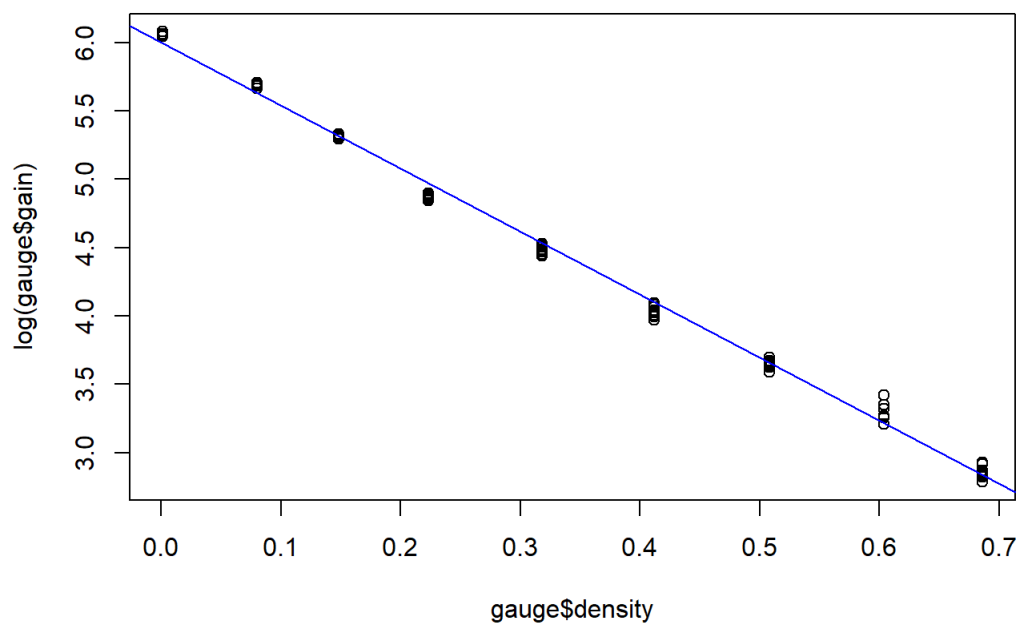


Wnioski i obserwacje: Narysowaliśmy wykres naszych danych z pliku "Gauge.csv" i dopasowaliśmy do nich model liniowy. Można powiedzieć, że model nie dopasował się do końca naszych danych gdyż wykres tych danych przypomina funkcję wykładniczą. Wykresy diagnostyczne potwierdzają wniosek.

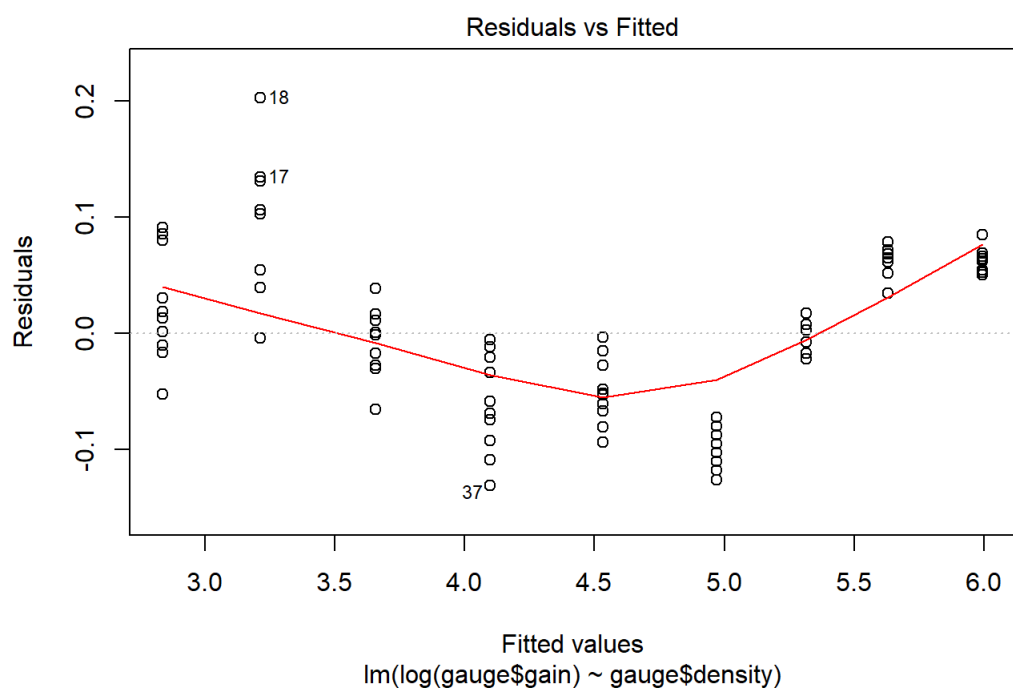
2. Jak wyglądają wykresy diagnostyczne, gdy zmienna zależna zostanie zlogarytmowana?



Zmienną zależną jest gain. ZLogarytmujmy ją w procesie modelu i porównajmy powstały model z poprzednim. ***


```
model.log <- lm(log(gauge$gain)~gauge$density)
plot(gauge$density,log(gauge$gain))
abline(model.log, col="blue")
```



```
plot(model.log) #wykresy diagnostyczne
```







Wnioski i obserwacje: Zmienna zależna jest lepiej dopasowana jak ją zlogarytmujemy. Wykresy diagnostyczne też wyglądają lepiej.

3. Na podstawie modelu logarytmicznego opracuj procedurę kalibracji. Dla wartości sygnału $\text{gain} = 38.6$ i $\text{gain} = 426.7$ znajdź przedziały ufności.

```
model.lin <- lm(log(gain)~density, gauge)
a <- model.lin$coefficients[[2]]
b <- model.lin$coefficients[[1]]

gain.observed <- 38.6
density.est <- a^(-1)*(log(gain.observed) - b)

#fh tells how much upper boundary of prediction interval differs from gain.observed
fh <- function(x) abs( predict(model.lin, newdata = data.frame(density = x), interval = "prediction")[3] - log(gain.observed))

#fh tells how much upper boundary of prediction interval differs from gain.observed
f1 <- function(x) abs( predict(model.lin, newdata = data.frame(density = x), interval = "prediction")[2] - log(gain.observed))

density.low <- optimize(f1, interval = c(0.01, 1))$minimum
density.high <- optimize(fh, interval = c(0.01, 1))$minimum

c(density.est, density.low, density.high)
```

```
## [1] 0.5089113 0.4793798 0.5385366
```

```
gain.observed2 <- 426.7
density.est2 <- a^(-1)*(log(gain.observed2) - b)
fh2 <- function(x) abs( predict(model.lin, newdata = data.frame(density = x), interval = "prediction")[3] - log(gain.observed2))
f12 <- function(x) abs( predict(model.lin, newdata = data.frame(density = x), interval = "prediction")[2] - log(gain.observed2))
density.low2 <- optimize(f12, interval = c(0.01, 1))$minimum
density.high2 <- optimize(fh2, interval = c(0.01, 1))$minimum
c(density.est2, density.low2, density.high2)
```

```
## [1] -0.01276954 0.01006520 0.01699373
```

Wnioski i obserwacje: Widzimy, że procedura kalibracji daje nam wartość 0.53. Dla wartości sygnału $\text{gain} = 38.6$ otrzymujemy gęstość 0.51 oraz przedział ufności $[0.5, 0.54]$. Dla $\text{gain} = 426.7$ gęstość -0.01 oraz przedział ufności $[0.01, 0.02]$.


4. Rozważ model $\log(\text{gain}) = a + b \cdot \text{density} + c \cdot \text{density}^2$. Jak wyglądają wykresy diagnostyczne?

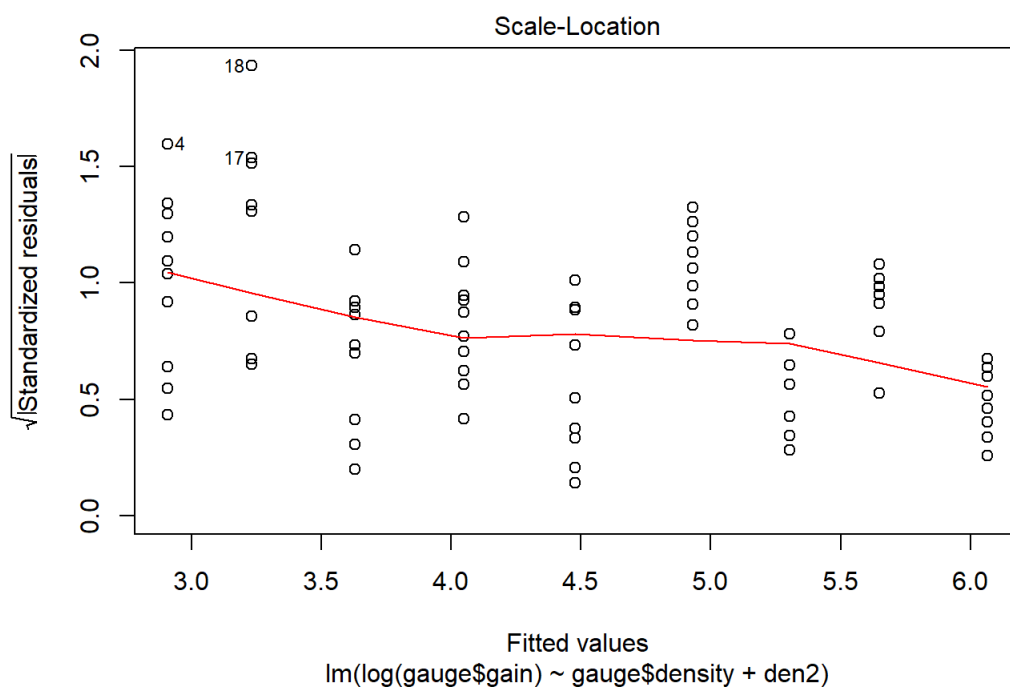

```
den2 <- (gauge$density)^2
model.den2 <- lm(log(gauge$gain)~gauge$density+den2)
summary(model.den2)
```


```
##
## Call:
## lm(formula = log(gauge$gain) ~ gauge$density + den2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.123698 -0.026099 -0.003998  0.030825  0.184439
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   6.07006    0.01263  480.569 < 2e-16 ***
## gauge$density -5.34675    0.08899  -60.083 < 2e-16 ***
## den2          1.07634    0.12471   8.631 2.56e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.05014 on 87 degrees of freedom
## Multiple R-squared:  0.9977, Adjusted R-squared:  0.9977
## F-statistic: 1.927e+04 on 2 and 87 DF,  p-value: < 2.2e-16
```

```
coef1<- model.den2$coefficients[[1]]
coef2 <- model.den2$coefficients[[2]]
coef3 <- model.den2$coefficients[[3]]

plot(model.den2)
```







coef1

[1] 6.070059

coef2

[1] -5.346754

coef3

[1] 1.076345

Wnioski i obserwacje: Model sie dopasowuje najlepiej ze wszystkich.